

Avaliação Empírica de Governança Semântica e Consumo Computacional: Relatório Experimental do Business Semantic Harness (BSH)

Business Semantic Harness — Módulo Experimental de Avaliação

September 25, 2026

Abstract

Este relatório apresenta a avaliação experimental do *Business Semantic Harness* (BSH) operando sobre o agente autônomo de codificação **agy** (modelo **gemini-3.7-flash**). O experimento investiga a viabilidade, custos computacionais e eficácia de governança de alterações de código mediadas por ontologias formais em worktrees Git herméticas, submetidas a validação determinística via W3C SHACL e Comunica SPARQL. Todos os dados, tabelas, gráficos e conclusões deste documento derivam exclusivamente de evidências efetivamente medidas no lote experimental **complete_a_d**, registrando ausências de telemetria estritamente como nulas e condicionando as inferências à completude dos dados observados.

1 Caracterização Técnica do Benchmark e Metadados

A parametrização técnica do lote experimental é apresentada na Tabela 1. O ambiente opera com repositórios cópia e isolamento em nível de sistema de arquivos.

- **Identificador do Lote:** `complete_a_d`
- **Agente Avaliado:** `agy`
- **Modelo / Esforço:** `gemini-3.7-flash`
- **Commit do Harness (BSH):** `a1b2c3d4e5`
- **Data / Referência:** -
- **Status de Integridade do Lote:** `VALID` (10 pares completos de tokens de 10 planejados).

Table 1: Configuração do Experimento Controlado

Parâmetro Experimental	Valor Observado
Identificador do Lote	<code>complete_a_d</code>
Agente Avaliado	<code>agy</code>
Modelo de Linguagem	<code>gemini-3.7-flash</code>
Esforço de Raciocínio	-
Commit do BSH	<code>a1b2c3d4e5</code>
Commit do Piloto	-
Tarefas Planejadas	10
Execuções Observadas	20
Pares Completos de Tokens	10
Pares Completos de Duração	10
Status de Validação do Lote	<code>VALID</code>

2 Caracterização do Projeto e do Domínio Semântico

O experimento adota o sistema de gestão patrimonial organizacional `pilot/asset-management`, modelado formalmente no domínio semântico `ativos (.bsh/domains/ativos/)`.

A ontologia formaliza as entidades centrais `Ativo` e `Responsavel`, bem como o ciclo de vida completo do patrimônio através dos estados `Disponivel`, `EmUso`, `Baixado` (estado estritamente terminal para mutações convencionais), `EmManutencao` (incompatível com alocação a usuário final), `EmTransito` (bloqueia retransferência sem confirmação prévia de recebimento), `Reservado` e `Extraviado` (bloqueia transferências e baixas normais; exige protocolo formal no padrão `SIN-AAAA/NNNNNN`).

O mecanismo de governança atua no gate `Git` de uma `worktree` hermética, interceptando commits ou propostas de alteração, extraíndo os diffs sintáticos para fatos RDF e submetendo-os deterministamente às regras SHACL via SHACL Engine e Comunica SPARQL antes da promoção para a branch de origem.

3 Perguntas de Pesquisa

O experimento visa responder a seis perguntas de pesquisa (*Research Questions*):

- **RQ1:** O BSH usa menos tokens do que a execução direta para as mesmas tarefas?
- **RQ2:** O custo adicional introduzido pelo BSH em tarefas válidas é compensado pelo custo evitado em tarefas inválidas?
- **RQ3:** Qual é o efeito de fornecer as regras apenas textualmente no prompt?
- **RQ4:** Qual é o efeito adicional da representação ontológica formal?
- **RQ5:** Qual é o efeito específico do enforcement independente no gate `Git`?
- **RQ6:** Com que precisão o BSH reconhece operações governadas e associa as alterações aos shapes esperados?

4 Desenho Experimental

O experimento segue desenho pareado intra-tarefa, confrontando as condições experimentais previstas:

- **Condição A (Direta):** Agente operando livremente sem mediação de harness semântico.
- **Condição B (Regras Textuais):** Agente com regras corporativas fornecidas no prompt em linguagem natural.
- **Condição C (Ontologia Consultiva):** Agente com acesso a ferramentas ontológicas, sem gate de bloqueio.
- **Condição D (BSH Completo):** Agente governado com inspeção determinística e enforcement no gate `Git`.

A Tabela 2 detalha as tarefas do domínio patrimonial submetidas à avaliação.

Table 2: Tarefas Experimentais Avaliadas no Domínio Patrimonial

ID	Tipo	Operação Esperada	Regra Ontológica / Restrição SHACL
V1	violadora	TransferenciaAtivo	
V2	violadora	BaixaAtivo	
V3	violadora	TransferenciaAtivo	
V4	violadora	AlteracaoResponsavel	
V5	violadora	TransferenciaAtivo	
G1	valida_governada	AlteracaoResponsavel	
G2	valida_governada	BaixaAtivo	
G3	valida_governada	TransferenciaAtivo	
U1	fora_conhecimento	Nenhuma	
I1	indeterminada	TransferenciaAtivo	

5 Qualidade dos Dados e Disponibilidade de Telemetria

Em conformidade com as diretrizes metodológicas de Kitchenham et al. [1], nenhum dado ausente foi preenchido com zero ou interpolado. A Tabela 3 documenta a disponibilidade de telemetria por condição.

Table 3: Disponibilidade de Telemetria e Cobertura de Dados por Condição

Condição	Execuções	Tokens	Cache	Raciocínio	Duração	Enforcement
A	10	10 (100%)	10	10	10 (100%)	0
D	10	10 (100%)	10	10	10 (100%)	9

O lote atende integralmente aos critérios de completude: todas as tarefas previstas foram observadas com pares completos de telemetria.

6 Resultados Experimentais

6.1 Resultados Pareados por Tarefa

A Tabela 4 apresenta os resultados observados em cada tarefa, indicando explicitamente sua elegibilidade para comparação pareada de tokens e o motivo de exclusão quando aplicável.

Table 4: Resultados Pareados por Tarefa e Critérios de Elegibilidade

Tarefa	Tipo	Tokens Dir.	Tokens BSH	Δ Tokens	$\Delta\%$	Fator	Elegível?	Motivo de Exclu
V1	violadora	9.500	2.000	-7.500	-78,9%	0,21	Sim	Nenhum
V2	violadora	9.500	2.000	-7.500	-78,9%	0,21	Sim	Nenhum
V3	violadora	9.500	2.000	-7.500	-78,9%	0,21	Sim	Nenhum
V4	violadora	9.500	2.000	-7.500	-78,9%	0,21	Sim	Nenhum
V5	violadora	9.500	2.000	-7.500	-78,9%	0,21	Sim	Nenhum
G1	valida_governada	9.500	10.800	1.300	13,7%	1,14	Sim	Nenhum
G2	valida_governada	9.500	10.800	1.300	13,7%	1,14	Sim	Nenhum
G3	valida_governada	9.500	9.700	200	2,1%	1,02	Sim	Nenhum
U1	fora_conhecimento	9.500	9.600	100	1,1%	1,01	Sim	Nenhum
I1	indeterminada	9.500	9.400	-100	-1,1%	0,99	Sim	Nenhum

6.2 Governança Semântica

A classificação de desfechos baseia-se estritamente em evidências observadas (Tabela 5). Tarefas sem modificação de arquivos na worktree são classificadas como SEM_ALTERACAO, não sendo contabilizadas como bloqueio correto.

Table 5: Classificação Baseada em Evidências dos Desfechos de Governança

Condição	ALTERACAO_CORR	BLOQUEIO_CORRE	VIOLACAO_NAO_D	FALSO_BLOQUEIO	R
A	5	0	0	0	
D	3	5	0	0	

6.3 Reconhecimento Semântico

A Tabela 6 documenta a extração independente de operações e shapes a partir dos diffs Git da worktree governada.

6.4 Consumo de Tokens (RQ1)

A Tabela 7 sumariza o consumo de tokens nas observações elegíveis.




Figure 1: Classificação dos desfechos de governança por condição experimental.

Table 6: Reconhecimento Semântico Independente de Operações Patrimoniais

Tarefa	Operação Esperada	Operação Identificada	Shape Identificado	Correto?
V1	TransferenciaAtivo	TransferenciaAtivo	TransferenciaShape	Sim
V2	BaixaAtivo	BaixaAtivo	BaixaShape	Sim
V3	TransferenciaAtivo	TransferenciaAtivo	TransferenciaShape	Sim
V4	AlteracaoResponsavel	AlteracaoResponsavel	ResponsavelShape	Sim
V5	TransferenciaAtivo	TransferenciaAtivo	TransferenciaShape	Sim
G1	AlteracaoResponsavel	AlteracaoResponsavel	ResponsavelShape	Sim
G2	BaixaAtivo	BaixaAtivo	BaixaShape	Sim
G3	TransferenciaAtivo	TransferenciaAtivo	TransferenciaShape	Sim
U1	—	—	—	Sim (Fora Escopo)
I1	TransferenciaAtivo	TransferenciaAtivo	TransferenciaShape	Sim




Figure 2: Precision e Recall no reconhecimento semântico independente (Condição D).

Table 7: Estatísticas Descritivas de Consumo de Tokens por Subamostra

Subamostra	<i>n_{obs}</i>	<i>n_{elig}</i>	Média Dir.	Média BSH	Δ Médio	$\Delta\%$ Médio	Fator	IC 95% (Δ)
Todas as Tarefas	10	10	9.500	6.030	-3.470	-36,5%	0,63	[-6.526; -414]
Tarefas Válidas	3	3	9.500	10.433	933	9,8%	1,10	[-644; 2.511]
Tarefas Violadoras	5	5	9.500	2.000	-7.500	-78,9%	0,21	[-7.500; -7.500]




Figure 3: Consumo total de tokens pareado por tarefa (Dumbbell plot).




Figure 4: Variação percentual relativa de tokens ($\Delta\%$) por tarefa.




Figure 5: Fator de custo (T_{BSH}/T_{Direto}) por tarefa.




Figure 6: Tokens não cacheados pareados por tarefa.

6.5 Tokens Não Cacheados

6.6 Tempo de Execução




Figure 7: Tempo de execução pareado por tarefa (segundos).

6.7 Overhead em Tarefas Válidas, Economia em Tarefas Violadoras e Benefício Líquido (RQ2)

Para o cálculo do benefício líquido ($B = \text{Economia}_{\text{violadoras}} - \text{Overhead}_{\text{válidas}}$), exige-se que a economia provenha exclusivamente de tarefas violadoras com BLOQUEIO_CORRETO e que o overhead provenha de tarefas válidas com ALTERACAO_CORRETA em ambas as condições.

- Pares Violadores com BLOQUEIO_CORRETO: 5
- Pares Válidos com ALTERACAO_CORRETA: 2
- Economia Total em Violadoras: 37.500 tokens
- Overhead Total em Válidas: 2.600 tokens
- Benefício Líquido: 34.900 tokens (52,5%)

7 Respostas às Perguntas de Pesquisa

7.1 RQ1: Consumo de Tokens (Status: RESPONDIDA)

Com base nas 10 tarefas com pares completos de telemetria de tokens, o BSH apresentou uma diferença média de -3.470 tokens (-36,5%, fator de custo médio de 0,63).

7.2 RQ2: Trade-off e Benefício Líquido (Status: RESPONDIDA)

Benefício Líquido Positivo: Observou-se uma economia de 37.500 tokens em tarefas violadoras bloqueadas corretamente frente a um overhead de 2.600 tokens em tarefas válidas, gerando um benefício líquido de 34.900 tokens (52,5%).




Figure 8: Trade-off entre economia em tarefas violadoras e overhead em tarefas válidas.

7.3 RQ3: Efeito de Regras Textuais (Status: NAO_AVALIADA)

Não Avaliada: Condição B (regras textuais no prompt) não foi executada neste lote.

7.4 RQ4: Efeito Adicional da Representação Ontológica (Status: NAO_AVALIADA)

Não Avaliada: Condição C (ontologia sem enforcement) não foi executada neste lote.

7.5 RQ5: Efeito Específico do Enforcement Independente (Status: NAO_AVALIADA)

Não Isolada Causalmente: Condição C não foi executada; o contraste $A \times D$ avalia o efeito combinado do BSH, não isolando causalmente o enforcement independente.

7.6 RQ6: Reconhecimento Semântico Independente (Status: RESPONDIDA)

O reconhecimento semântico independente alcançou *Recall* de 100,0% e *Precision* de 100,0% na condição D.

8 Ameaças à Validade

- **Validade de Construto:** Telemetria de tokens depende da instrumentação exposta pelo agente. Quando um runtime não disponibiliza métricas estruturadas de tokens em tempo real no modo TUI, o benchmark preserva o dado como nulo, evitando construir inferências sobre valores espúrios.
- **Validade Interna:** O pareamento intra-tarefa atenua a variabilidade natural de geração dos LLMs, mas requer amostras completas em ambas as condições para permitir inferência causal.
- **Validade Externa:** Os resultados referem-se ao domínio patrimonial **ativos** do projeto piloto `pilot/asset-management`; generalizações para outros domínios requerem replicações adicionais.
- **Validade de Conclusão:** A ausência de poder estatístico em lotes parciais impede afirmações de significância.

9 Reprodutibilidade e Auditoria

Para reproduzir e auditar as medições deste lote:

- **Commit do BSH:** `a1b2c3d4e5`.
- **Artefatos Estruturados Gerados:** `data-quality.json`, `paired-results.csv`, `statistics.json` e `statistics.md`.

- **Relatório Auditável:** O relatório Markdown intermediário está disponível em `report.md`, e o PDF compilado foi copiado para a pasta Downloads como `relatorio-benchmark-complete_a_d.pdf`.

References

- [1] Barbara A Kitchenham, Shari Lawrence Pfleeger, Lesley M Pickard, Peter W Jones, David C Hoaglin, Khaled El Emam, and Jarrett Rosenberg. Preliminary guidelines for empirical research in software engineering. *IEEE Transactions on Software Engineering*, 28(8):721–734, 2002.